

ИТОГОВЫЙ проект

Тема: Парсинг блога Top Academy и
разработка ORM



Итоговый проект

В этом модуле мы изучили основы парсинга веб-страниц и работу с базами данных, а также освоили использование **SQLite** в **Python**. Мы научились собирать, структурировать и хранить данные из интернета.

Сегодня мы применим навыки работы с библиотеками `requests`, **BeautifulSoup** и **SQLite** на практике, чтобы собрать данные из блога Top Academy.



Ситуация

Вы получили задание от команды блога **Top Academy**. Вам поручили автоматизировать мониторинг образовательного контента в блоге. Маркетинговый отдел хочет регулярно анализировать тематику статей, чтобы выявлять популярные направления и адаптировать учебные программы.

Кроме того, преподаватели просят создать архив материалов для быстрого доступа к методическим статьям в формате **SQL**.



ЗАДАЧА

Разработать систему парсинга и хранения данных блога Top Academy:

1. Сбор данных:

- Используйте библиотеки **requests** и **BeautifulSoup** для парсинга главной страницы блога.
- Извлеките заголовки (**h1**) и тексты статей (**p**) из блоков с классом **styles_cardBody__qP0jN**.

ЗАДАЧА

Разработать систему парсинга и хранения данных блога Top Academy:

2. Структурирование данных:

- Преобразуйте сырые данные в объекты класса **BlogArticle** с полями **title** и **text**.
- Реализуйте методы **to_dict()** и **from_dict()** для удобной конвертации данных.

ЗАДАЧА

Разработать систему парсинга и хранения данных блога Top Academy:

3. Работа с базой данных

- Создайте SQLite-базу **top_academy_blog.db** с таблицей `articles` (поля: **id**, **title**, **text**).
- Реализуйте сохранение статей через **INSERT OR IGNORE**, чтобы избежать дублирования.

ЗАДАЧА

Разработать систему парсинга и хранения данных блога Top Academy:

4. Анализ контента

- Проверьте, сколько статей удалось сохранить в БД (**saved_count**).
- Выведите первые 5 записей из базы, чтобы убедиться в корректности данных.

ПРИМЕР РАБОТЫ ПРОГРАММЫ

При запуске script.py выполняется функция `main()`, которая:

1. Создает экземпляр парсера **BlogParser**.
2. Загружает HTML-код страницы блога **Top Academy** (<https://msk.top-academy.ru/blog>).
3. Извлекает данные статей (заголовки и текст).
4. Сохраняет их в базу данных **SQLite**.
5. Выводит первые 5 записей для проверки.



ОЖИДАЕМЫЙ РЕЗУЛЬТАТ

Программа должна корректно выполнить парсинг блога Top Academy, сохранить извлеченные данные в базу данных SQLite и вывести на экран отчет о проделанной работе с примерами сохраненных статей.

Вывод результата

Сохранение данных в базу данных...

Успешно сохранено 12 статей в top_academy_blog.db.

Последние 5 добавленных статей:

1. Заголовок: "Основы Python для начинающих"

Текст: "Python - это интерпретируемый язык программирования..."

...

Парсинг завершен успешно. Все данные сохранены в базе.

КРИТЕРИИ ОЦЕНИВАНИЯ:

4 балла — Основной функционал:

Программа успешно подключается к сайту Top Academy и загружает HTML-страницу блога.

Парсер корректно извлекает заголовки (h1) и тексты (p) статей с использованием BeautifulSoup.

Данные преобразуются в объекты BlogArticle и сохраняются в SQLite-базу top_academy_blog.db.

Выводится отчет о количестве сохраненных статей и примеры данных (первые 5 записей).



МАКСИМАЛЬНЫЙ БАЛЛ
ЗА ЗАДАНИЕ:

12 БАЛЛОВ

КРИТЕРИИ ОЦЕНИВАНИЯ:

4 балла — Работа с данными:

Реализована структура БД: таблица `articles` с полями `id`, `title`, `text`.

Используется `INSERT OR IGNORE` для исключения дубликатов.

Данные из БД корректно извлекаются методом `get_all_articles()`.

Обработка ошибок: проверка статуса HTTP-запроса, обработка исключений при парсинге.



МАКСИМАЛЬНЫЙ БАЛЛ
ЗА ЗАДАНИЕ:

12 БАЛЛОВ

КРИТЕРИИ ОЦЕНИВАНИЯ:

4 балла — Работа с sqlite3:

Код реализован в стиле объектно-ориентированного программирования (с использованием классов).

Программа корректно устанавливает соединение с базой данных `top_academy_blog.db`.

Создан объект `cursor`, который выполняет SQL-запросы. Используется `fetchall()` для извлечения результатов и их вывода.

В конце работы соединение закрывается с помощью `close()`.



МАКСИМАЛЬНЫЙ БАЛЛ
ЗА ЗАДАНИЕ:

12 БАЛЛОВ